边缘集群AI推理的分布式任务调度

时间限制: 30s 空间限制: 512MB

背景信息

在多用户共享算力资源的场景下,由于推理任务的启动时间不同步、性能需求差异显著,加之服务器本身的异构性,系统会面临复杂的调度需求。

需要选手设计调度算法,尽可能满足多个用户的吞吐量需求。

题目描述

多个用户在不同时刻有不同的推理请求,为处理请求提供多种服务器。选手需要通过把请求放置于服务器上,并采用迁移操作 使得尽可能满足吞吐量需求。

以下是相关信息的详细描述:

- 服务器: 提供N台服务器,第i台服务器有 g_i 个NPU,显存大小是 $m_i\ MB$ 。单个服务器的所有NPU是相同的。
- 推理耗时:第i种服务器的单个NPU同时处理多个请求时,该NPU上的第j个请求的耗时是 $\left\lceil \frac{B_j}{f(B_j)} \right\rceil$ 毫秒,其中 $f(B_j)=k_i*\sqrt{B_j}$ 表示推理速度, k_i 表示该NPU的推理速度系数, B_j 表示第j个请求的batchsize。请求在第x毫秒开始推理,推理耗时y毫秒,则该请求在第x+y毫秒完成推理。不考虑模型加载耗时。
- 显存: $Memory=a_i*batchsize+b_i$ 表示显存与batchsize的关系。 a_i,b_i 表示第i个用户使用的模型的固有参数。
- 用户: 共有M个用户有推理诉求。其中第i个用户希望在第 $[s_i,e_i)$ 毫秒内推理 cnt_i 个样本。
- 通信时延: 第i个用户把请求发送到第j种服务器的通信时延是 $latency_{j,i}$ 毫秒,即用户在第x毫秒发送请求,服务器在第 $x+latency_{j,i}$ 毫秒收到请求。用户可在第 $x+latency_{j,i}+1$ 毫秒发送下一个请求。
- 迁移次数: 形式化地,第i个用户在同一时刻只能发送一个请求,记接收该请求的NPU编号是v。按照时间顺序,该用户发送第一个请求到最后一个请求形成的v序列是V。记V的长度是L, $move_i=\sum_{i=1}^{L-1}[V_i!=V_{i+1}]$,则该用户得分随 $move_i$ 增加而减少,具体细节见评分规则。
- 推理顺序:每个NPU对应一个队列,队列内存储**未完成推理**的请求。队列排序的第一关键字是请求到达该NPU所在服务器的时刻,越早到达的请求越靠近队首。对于同时到达的请求,编号越小的用户发送的请求越靠近队首。每毫秒会处理一次队列。按照先后顺序执行的处理方式如下:
 - 1. 移除已完成推理的请求。
 - 2. 增加当前时刻接收到的请求。
 - 3. 将序列排序。
 - 4. 从队首至队尾依次扫描请求,若加上该请求所需显存后未超过服务器显存,则认为本毫秒对该请求分配推理资源。

备注:本题的最小时间单位是毫秒,不可拆分。

对用户引入权重概念,认为不同用户的重要性是不同的,具体规则见评分规则。

题目交互

输入

第一行一个整数 $N(1 \leq N \leq 10)$ 表示服务器种类数。

接着N行,每行3个整数 $g_i, k_i, m_i (1 \leq g_i \leq 10, 1 \leq k_i \leq 5, 1000 \leq m_i \leq 2000)$,其中 g_i 表示第i台服务器NPU个数, k_i 表示推理速度参数, m_i 表示NPU显存大小。与上文"服务器"含义一致。

接着一行,该行一个整数M(1 < M < 500)表示用户数量。

接着M行,每行3个整数 $s_i, e_i, cnt_i (0 \le s_i < e_i \le 60000, 1 \le cnt_i \le 6000, 5 \times cnt_i \le e_i - s_i)$,其中 s_i, e_i 表示用户的推理请求时间段 $[s_i, e_i)$, cnt_i 表示待推理样本数量。

接着N行,每行M个整数,其中第i行第j个整数 $latency_{i,j}(10 \leq latency_{i,j} \leq 20)$ 表示第j个用户把请求发送到第i种服务器的通信时延。

接着一行,该行两个整数 $a,b(10 \le a \le 20,100 \le b \le 200)$ 表示显存和batchsize的关系。

接着M行,每行2个整数 a_i,b_i $(10 \le a_i \le 20,100 \le b_i \le 200)$ 表示第i个用户使用的模型的显存和batchsize的关系。

输出

输出2M行,第2i-1行和第2i行表示第i个用户的推理方案。

第2i-1行包含一个整数 T_i ,需要保证 $1 \le T_i \le 300$ 。

第2i行包含 $4T_i$ 个整数,第4j-3个整数 $time_j (0 \leq time_j < time_{j+1} \leq 1000000, time_{T_i+1} = +\infty)$,第4j-2个整数 $server_j (1 \leq server_j \leq N)$,第4j-1个整数 $NPU_j (1 \leq NPU_j \leq g_i)$,第4j个整数 $B_j (1 \leq B_j \leq 1000), a \times B_j + b \leq m_{server_j}$,表示第i个用户在 $time_j$ 时刻将包含 B_j 个推理样本的请求发送给第 $server_j$ 台服务器的第 NPU_j 个NPU。选手需保证 $time_1 \geq s_i, \sum_{j=1}^{T_i} B_j = cnt_i$ 。

评分规则

单个测试用例得分 $Score=h(K) imes\sum_{i=1}^Mh(rac{end_i-e_i}{e_i-s_i}) imes p(move_i) imes\mathbf{q(i)} imes\mathbf{10000}$,其中 end_i 表示该用户的最后一个样本推理完成的时刻, $K=\sum_{i=1}^M[end_i>e_i]$, $h(x)=2^{-\frac{x}{100}}$, $p(x)=2^{-\frac{x}{200}}$, $\mathbf{q(x)}=\mathbf{2^{-\frac{x}{5000}}}$ 。

选手总得分为所有测试用例得分之和。

样例

输入

2

2 3 10000

```
6 5 20000

3

0 60000 3000

10000 50000 2000

0 200000 5000

10 20 20

20 10 12

10 100
```

输出

备注:输入输出仅为说明格式。

错误类型

基础错误类型

- 1. 代码编译错误
- 2. 程序异常退出 (可能原因: 运行错误,使用异常权限,输出参数比实际多,输出参数格式不对,etc...)
- 3. 超出时间限制(可能原因: 交互时未使用清空流缓存命令,程序运行超时,输出参数比实际少,etc...)
- 4. 超出内存限制

逻辑错误类型

- "Unknown Error" (出现时请联系大赛方)
- "RE" (程序内存访问越界或异常退出)
- "Invalid Output" (T_i 或者 $time_j$ 违反约束)
- "Batchsize Exceeds Memory" (B_j 违反约束)

- "Samples Not Fully Processed" (样本未全部发送)
- "Invalid Time Order" ($time_j$ 非递增)
- "Invalid NPU Index" (NPU编号违反约束)
- "Invalid User Send Time" (样本发送时刻早于允许发送的时刻)
- "Invalid Server Index" (服务器编号违反约束)